


ML / DL : PBL 01

« Подготовка данных и разведочный разбор данных о
диагностике диабета »



SK Shieldus

Rookies, 30-й набор (личный номер 14)

Ким Джэ-Ук

Решение PBL 01

```
import pandas as pd
import numpy as np
from sklearn.preprocessing import MinMaxScaler

# загружаем данные
data = pd.read_csv("20260109_142630_diabetes.csv")
print(f"Общее число наблюдений в данных {len(data)}")
print("-" * 55)

# до обработки считаем нули в тех столбцах,
# где ноль надо понимать как пропуск
# - 1 - пять столбцов, которые нас занимают прежде всего
missing_zero_features = ["Glucose", "BloodPressure", "SkinThickness",
                          "Insulin", "BMI"]
zero_counts_before = data[missing_zero_features].eq(0).sum()
print("Число нулей, считаемых пропусками, в этих пяти столбцах\n",
      zero_counts_before)
print("-" * 55)

# - 2 - проверяем пропуски в остальных столбцах, и вместе с - 1 -
# это даёт число пропусков сразу по всем столбцам
other_cols = data.columns.difference(missing_zero_features)
zero_counts_other = data[other_cols].eq(0).sum()
print("Число нулей в остальных столбцах\n", zero_counts_other)
print("-" * 55)

# а вдруг пропуск записан не нулём, а иначе, то есть NaN или None,
# эта мысль появилась благодаря вопросу учащегося Син Вон Сопа
has_other_missing = data.isnull().any().any()
print("Есть ли пропуски не в виде нуля, то есть NaN или None ",
      has_other_missing)
```

Общее число наблюдений в данных 768

Число нулей, считаемых пропусками, в этих пяти столбцах

Glucose	5
BloodPressure	35
SkinThickness	227
Insulin	374
BMI	11

dtype: int64

Число нулей в остальных столбцах

Age	0
-----	---

```
DiabetesPedigreeFunction    0
Outcome                     500
Pregnancies                  111
dtype: int64
```

```
Есть ли пропуски не в виде нуля, то есть NaN или None  False
```

```
# нужен, чтобы показывать таблицы в виде HTML
from IPython.display import HTML
# так сделано потому, что по опыту обычные таблицы, которые
# Quarto выводит в PDF, читаются очень плохо
```

```
# заменяем нули на NaN, а затем ставим вместо них среднее
# внимание, по условию задания это делается только для тех
# пяти столбцов, о которых сказано в - 1 -
for feat in missing_zero_features:
    data[feat] = data[feat].replace(0, np.nan)

# считаем число NaN в этих пяти столбцах
missing_counts_after_zero_to_nan = data[missing_zero_features].isnull().sum()
# меняем вид таблицы, чтобы вывести её как HTML
missing_counts_after_zero_to_nan = (
    missing_counts_after_zero_to_nan
    # переносим индекс в обычный столбец
    .reset_index()
    # приводим названия столбцов в порядок
    .rename(columns={"index": "Column", 0: "Число NaN"})
)
# выводим таблицу в виде HTML вместе с рамкой
HTML(missing_counts_after_zero_to_nan.to_html(index=False, border=1))
```

Column	Число NaN
Glucose	5
BloodPressure	35
SkinThickness	227
Insulin	374
BMI	11

```
for feat in missing_zero_features:
    # ставим вместо пропусков среднее значение столбца
    data[feat] = data[feat].fillna(data[feat].mean())

# работа с выбросами, значения выше верхнего одного процента
# считаем ненормальными и заменяем их средним
# столбцы, в которых убираем выбросы
outlier_features = ["SkinThickness", "Insulin"]
# перебираем каждый такой столбец
for feature in outlier_features:
    # находим границу верхнего одного процента
    upper_percentile_99 = data[feature].quantile(0.99)
    # значения до границы оставляем как есть,
```

```

# а всё, что выше границы, превращаем в NaN
data[feature] = data[feature].where(data[feature] <= upper_percentile_99,
                                     np.nan)
# ставим вместо этих NaN среднее значение
data[feature] = data[feature].fillna(data[feature].mean())

# приводим к промежутку от 0 до 1 только столбец Age,
# потому что по условию задания это нужно лишь для Age
scaler = MinMaxScaler()
data[["Age"]] = scaler.fit_transform(data[["Age"]])

# проверяем, остались ли пропуски после обработки, ведь в исходных
# данных NaN не было, они появились после замены нулей,
# а затем были заполнены средним
missing_after = data.isnull().sum()
# меняем вид таблицы, чтобы вывести её как HTML
missing_after = (
    missing_after
    # переносим индекс в обычный столбец
    .reset_index()
    # приводим названия столбцов в порядок
    .rename(columns={"index": "Column", 0: "Число NaN"}))
HTML(missing_after.to_html(index=False, border=1))

```

Column	Число NaN
Pregnancies	0
Glucose	0
BloodPressure	0
SkinThickness	0
Insulin	0
BMI	0
DiabetesPedigreeFunction	0
Age	0
Outcome	0

```

# сравниваем среднее значение Glucose по группам Outcome
glucose_mean_by_outcome = (
    # группируем по Outcome и берём столбец Glucose
    data.groupby("Outcome")["Glucose"]
    # считаем среднее в каждой группе
    .mean()
    # превращаем результат обратно в таблицу
    .reset_index()
    # даём столбцу более понятное название

```

```
.rename(columns={"Glucose": "Среднее Glucose"})
)

HTML(glucose_mean_by_outcome.to_html(index=False, border=1))
```

Outcome	Среднее Glucose
0	110.710121
1	142.165573

```
# смотрим часть итогового результата обработки
# сокращаем название столбца, потому что иначе таблица обрезается
# или переносится на новую строку и читать её становится неудобно
data = data.rename(columns={"DiabetesPedigreeFunction": "DPF"})
# берём первые пять строк готовых данных и убираем прежний индекс
summary = data.head().reset_index(drop=True)
HTML(summary.to_html(index=False, border=1))
```

Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DPF	Age	Outcome
6	148.0	72.0	35.00000	155.548223	33.6	0.627	0.483333	1
1	85.0	66.0	29.00000	155.548223	26.6	0.351	0.166667	0
8	183.0	64.0	29.15342	155.548223	23.3	0.672	0.183333	1
1	89.0	66.0	23.00000	94.000000	28.1	0.167	0.000000	0
0	137.0	40.0	35.00000	168.000000	43.1	2.288	0.200000	1

В таблице выше DPF в седьмом столбце это сокращение от DiabetesPedigreeFunction.

Толкование результатов

Если учитывать смысл задания, а именно « **выполнить начальную подготовку данных и разведочный разбор на основе данных о диагностике диабета** », то приведённое ниже **толкование результатов** тоже оказывается осмысленным.

- (1) Прежде всего, до обработки была проверена картина по тем переменным, где ноль понимается как пропуск (Glucose, BloodPressure, SkinThickness, Insulin, BMI), и число таких нулей по каждой переменной оказалось следующим, а именно **Glucose 5, BloodPressure 35, SkinThickness 227, Insulin 374, BMI 11**. Особенно заметно, что **у SkinThickness (227) и у Insulin (374) значений, считаемых пропусками, очень много**, причём **у переменной Insulin нулём записаны 374 наблюдения из всех 768**, и по этим числам ясно видно, что восполнение пропусков именно в этой переменной становится ключевым шагом подготовки данных. Отсюда следует, что для этих данных порядок работы, при котором в пяти указанных переменных ноль считают пропуском и заменяют средним, совершенно необходим (то есть оставлять пропуски без внимания нельзя).
- (2) Далее, после работы с пропусками (замена 0 → NaN и затем подстановка среднего) и после работы с выбросами (в переменных **SkinThickness, Insulin** значения выше верхнего одного процента переведены в NaN и заменены средним) к столбцу **Age** было применено **приведение к промежутку от 0 до 1** способом **Min-Max**. Если посмотреть на результат подготовки, данные выводятся в упорядоченном виде и уже без пропусков, а в первых пяти строках готовых данных видно, что значения **Age** приведены к промежутку от 0 до 1 (например, 0.483333, 0.166667 и подобные). Затем среднее значение **Glucose** было сопоставлено по группам **Outcome**, и оказалось, что **среднее Glucose при Outcome=0 равно 110.710121, а при Outcome=1 равно 142.165573**, то есть **у группы Outcome=1 среднее значение Glucose заметно выше, чем у группы Outcome=0**. Иначе говоря, с точки зрения начального разведочного разбора видна склонность к более высокому уровню сахара в крови (Glucose) в группе с поставленным диагнозом (Outcome=1), и это указывает на то, что **Glucose может быть одной из главных переменных, связанных с Outcome**.

В целом описанная подготовка данных и сводные результаты имеют смысл потому, что **для указанных переменных с большим числом нулей (Glucose, BloodPressure, SkinThickness, Insulin, BMI) были восполнены пропуски и убраны выбросы, для Age было выполнено приведение к промежутку от 0 до 1, а затем была проверена разница средних значений Glucose в зависимости от Outcome**. Поэтому всё это может служить основанием, которое подтверждает разумность простого, но полностью отвечающего условию задания порядка подготовки данных и разведочного разбора для работы с данными о диабете.

Наблюдение о самом наборе данных

-прежде всего о большом числе пропусков у переменных SkinThickness и Insulin-

« Но всё же ... если вернуться к пункту (1) толкования результатов, почему же (!) именно у SkinThickness и Insulin особенно много пропусков ? »

Прежде всего, как причину того, что пропусков особенно много именно у SkinThickness и Insulin, можно выдвинуть предположение, что при первичной постановке диагноза диабета эти показатели считались менее важными, чем Glucose, то есть чем сахар в крови. А именно, в журнале, который Американская диабетическая ассоциация (American Diabetes Association) официально выпустила по поводу постановки диагноза диабета [1] Guidelines and Recommendations for Laboratory Analysis in the Diagnosis and Management of Diabetes Mellitus (если точнее, на странице с89 в разделе 2. Analytical considerations, в абзаце, который начинается со слов Measurements of), есть прямое указание, что уже (!) с 2011 года при OGTT (= Oral Glucose Tolerance Test, то есть проба с сахарной нагрузкой), одним из способов постановки диагноза, измерение инсулина не следует использовать для постановки диагноза диабета. "... *insulin measurement should not be used in an OGTT to diagnose diabetes*"

Однако при толковании важно помнить, что сказанное выше не означает, будто инсулин не связан с диабетом.

Если учитывать механизм самой болезни, такое толкование **не** было бы разумным.

И всё же, с точки зрения **постановки диагноза**, предположение, что измерение инсулина уступало по важности измерению сахара в крови, выглядит вполне разумным. Любопытно, что это не расходится с нашим повседневным опытом. Если говорить точнее, при сдаче крови в обычной районной поликлинике для первичной проверки на диабет обычно измеряют **сахар натощак**, а инсулин (Insulin) не измеряют. Прошу обратить внимание на материалы об анализах крови на страницах 6 и 7.

Но почему же то, что показатель уступал другим по важности, могло породить такое большое число пропусков? Посмотрим ещё раз спокойно на то, из чего состоят столбцы этих данных.

Pregnancies (число беременности ?) , **Glucose** (сахар в крови) , **BloodPressure** (давление) , **SkinThickness** (замер определённого места калипером) , **Insulin** (инсулин) , **BMI** , **Diabetes-PedigreeFunction** (наличие болезни у родных) , **Age** (возраст)

По сравнению с остальными показателями инсулин (Insulin) уступал по важности, а SkinThickness с точки зрения навыка того, кто проводит замер, и доступности медицинской помощи заметно хуже подходит для первичной проверки на диабет у большого числа людей. Поэтому весьма вероятно, что случаи, когда эти два замера просто пропускали, и отразились в данных как пропущенные значения.

Из сказанного выше можно заключить, что **предоставленные данные не оторваны от действительности, а наоборот, отражают её лучше и дают понимание того, как обстоят дела в настоящей медицинской практике**.

※ При этих размышлениях сильно помогло занятие курса *Big Data and Machine Learning in Healthcare*, который завершился 20 декабря 2025 года, а именно третье занятие *Making Sense Of Data* от 20 сентября того же года, где шло напряжённое обсуждение. Ссылку на сайт с использованными учебными материалами прилагаю как источник.

[2] <https://medicalanalytics.group/big-data-and-machine-learning-in-healthcare>

일반 혈액검사(혈구 검사, Complete blood test [CBC])

혈구 검사항목	정상범위 (단위)	임상적 의의
백혈구(WBC)	4.0~10.0 ($10^9/L$)	· 다음과 같은 여러 가지 그룹의 세포집단으로서 다양한 감염원으로부터 인체를 보호한다. · 증가: 활동성 감염, 탈수, 외상, 종양, 골수증식 질환, 백혈병 · 감소: 일부감염, 약물, 골수 기능 저하 등
호중구(Neutrophil)	50~75 (%)	· 주로 세균 감염에서 증가하며, 일부 바이러스 감염에서 그 비율이 감소
림프구(Lymphocytes)	20~44 (%)	· 일부 바이러스 감염 및 림프구 증식 질환에서 그 비율이 증가
단구 (Monocytes)	2~9 (%)	· 일부 감염, 자가면역질환 및 골수증식 질환에서 그 비율이 증가
호산구 (Eosinophil)	0~5 (%)	· 기생충 감염 및 알레르기 질환, 종양, 약물에 의해 그 비율이 증가
호염기구 (Basophil)	0~2 (%)	· 악성 종양의 전이, 알레르기 질환 등에서 그 비율이 증가
적혈구 (RBC)	4.0~5.0 ($10^{12}/L$)	· 납작한 구 모양으로 산소와 결합하는 헤모글로빈을 지니고 있음 · 증가: 설사, 탈수, 저산소증, 약물 중독, 골수 증식 질환 · 감소: 용혈, 출혈, 철분 및 비타민B12 부족, 골수 기능 저하
헤모글로빈(Hb)	12.0~16.0 (g/dl)	· 산소와 결합 가능한 헤모글로빈의 수치 · 폐에서 조직으로 산소 운반, 조직에서 폐로 탄산가스 운반
헤마토크릿 (Hct)	34.0~49.0 (%)	· 혈장에 대한 적혈구의 비율
MCV (적혈구평균용적)	79~95 (fl)	· 적혈구의 평균 크기 · 증가: 비타민 B1 혹은 엽산 결핍, 용혈, 골수 기능 부전 · 감소: 철분 결핍, 지중해빈혈, 철적혈모구빈혈
MCH (평균헤모글로빈)	26~32 (pg)	· 한 개의 적혈구에 들어있는 헤모글로빈 수치
RDW (적혈구 분포폭)	11.5~14.5 (%)	· 적혈구 크기의 분포, 빈혈 환자에서 그 수치가 감소
혈소판 (Platelet)	150~450 ($10^9/L$)	· 일차 지혈을 담당하는 세포로서 피막지를 형성 · 증가: 빈혈, 감염, 골수 증식 질환 · 감소: 약물, 감염, 면역성 혈소판 감소, 백혈병, 골수 기능 저하
PDW (혈소판 분포폭)	9.13~19.41 (fl)	· 면역혈소판감소증, 골수 기능 저하, 백혈병 등에서 증가

Figure 1: Больница Святой Марии в Сеуле при Католическом университете, отделение крови (общий анализ крови)

Ни инсулина (Insulin), ни SkinThickness среди пунктов обследования нигде нет.

생화학검사(Blood chemistry)

생화학 검사 항목	정상범위 (단위)	임상적 의의
Glucose	50~100 (mg/dL)	· 혈당, 주로 당뇨 환자에서 증가하는 수치 · 혈액암의 치료, 이식 후 사용하는 면역억제제, 특히 스테로이드 성분의 약은 혈당의 증가 원인
Urea Nitrogen (BUN)	7.0~20.0 (mg/dL)	· 요소 질소의 양 · 발열, 출혈, 스트레스, 신장질환, 요로감염 등에서 증가
Creatinine (Cr)	0.6~1.2 (mg/dL)	· 신장 기능 저하를 나타내는 대표적인 수치 · 근육 내에 존재하는 효소로서 신장을 통하여 배설
Total Protein	6.6~8.3 (g/dL)	· 혈장 내에 존재하는 각종 단백질의 전체 양 · 탈수로 인한 혈액 농축 시 증가 · 혈액 질환 중에는 다발골수종에서 특이적으로 증가
Albumin	3.5~5.2 (g/dL)	· 간에서 주로 생산되는 단백질로서 혈액 내 삼투압 조절 및 수분양을 유지 · 감소할 경우 부종의 원인 · 만성 간질환, 영양장애, 신증후군 등에서 감소
AST(GOT)	14~40 (U/L)	· 간, 심장, 신장, 근육 등에 존재 · 해당 부위의 각종 질환에서 혈액 내로 유출되면 증가 · 간염, 심근경색, 간암, 담낭 질환 등에서 증가
ALT(GPT)	9~45 (U/L)	· 주로 간에 존재하는 효소 · 간염, 담낭염, 담관염, 간암, 저산소성 손상 등에서 증가
Total Bilirubin	0.47~1.58 (mg/dL)	· 황달 수치 · 주로 용혈빈혈, 악성빈혈, 간기능장애, 담낭 및 담관 질환에서 증가
Uric acid	2.6~7.2 (mg/dL)	· 요산 수치 · 혈액암 환자의 항암 후 증양용해증후군에서 증가 · 신장 기능 저하의 원인 · 일반적으로 통풍 및 비만 환자에서 증가
LDH	250~450 (U/L)	· 림프종 및 용혈빈혈에서 증가 · 치료 경과를 반영
CPK	26~200 (U/L)	· 심장 및 근육에 존재하는 효소 · 심근이 파괴되었거나, 근육 손상이 되었을 경우 증가
Magnesium	1.9~2.5 (mg/dL)	· 면역억제제 투여 혹은 설사, 감염증에서 감소 · 근육 경련의 원인이 됨
Calcium (Ca)	8.0~10.0 (mg/dL)	· 골질환 및 내분비 질환에서 진단적 의의 · 증가 : 갑상선항진증, 비타민D 과잉, 뼈의 파괴, 악성 종양 · 감소 : 설사, 급성 췌장염, 종양용해증후군
Phosphorus (P)	2.6~4.5 (mg/dL)	· 뼈의 저장과 용출에 중요한 성분, 신장으로 배출 · 증가 : 종양 용해 증후군, 신부전증, 부갑상선기능항진증
Sodium (Na)	136~146 (mEq/L)	· 나트륨 수치 · 체내 수분량 평가 · 증가 : 염분과잉, 탈수, 설사, 감염, 나트륨배설저하 (알도스테론과잉, 쿠싱, 요붕증) · 감소 : 염분섭취저하, 구토, 수분과다, ADH분비억제
Potassium (K)	3.5~5.1 (mEq/L)	· 칼륨 수치 · 삼투압 및 산-염기 평형 반영 · 신장기능저하 시 증가 · 심장마비로 인한 급사의 원인이 됨
Chloride (Cl)	98~106 (mEq/L)	· 염소 수치 · 삼투압 및 산-염기 평형 반영

Figure 2: Больница Святой Марии в Сеуле при Католическом университете, отделение крови (биохимический анализ)

Этот документ подготовлен в формате **Quarto Markdown** (.qmd), который позволяет объединять код **Python** и текст документа в одном файле, он написан в **R Studio** и выведен в формате PDF.

Использованные материалы

- [1] D. B. Sacks *et al.*, "Guidelines and recommendations for laboratory analysis in the diagnosis and management of diabetes mellitus," *Diabetes Care*, 2011, doi: [10.2337/dc11-9998](https://doi.org/10.2337/dc11-9998).
- [2] O. S. Pinykh, "Big Data and Machine Learning in Healthcare Applications — Department of Radiology, Massachusetts General Hospital, Harvard Medical School." Accessed: Jan. 09, 2026. [Online]. Available: <https://medicalanalytics.group/big-data-and-machine-learning-in-healthcare>